


SpeedSketch: Сверхбыстрый фреймворк генерации эскизов и дельта-кодирования для дельта-сжатия

Основные критические этапы с высокими вычислительными затратами:

- Sketch Generation
- Delta Encoding


Основные проблемы:

- Вычислительная сложность на множество генераций скетчей
- Затраты на сравнение всех слов со словами в базовом блоке
- Дублирующиеся вычисления на этапах генерации скетчей и дельта-кодирования



Предложения SpeedSketch:

- Объединяет генерацию скетчей и дельта-кодирование в дельта-сжатии
- Инновационная схема генерации эскизов с помощью операций классификации и маскирования отпечатков
- Используем скетчи для оптимизации дельта-кодирования за счет пропуска слов



До SpeedSketch:

- 1) Вычисляем отпечаток для каждого слова в базовом чанке и заносим в таблицу
- 2) Ищем идентичный отпечаток слова в входном чанке
- 3.1) Если находим => Помечаем как Copy
- 3.2) Если не находим => Помечаем как Insert






Figure 2: The process of Delta Encoding.

Модуль генерации скетчей:


- Генерация отпечатков для каждого слова
- Классификация каждого отпечатка
- Генерация набора прокси

Модуль дельта-кодирования :

- Вычисление отпечатков для базового блока и заполнение Fp Table.
- Оценка наличия каждого слова входного блока в базовом блоке
- Поиск в Fp Table только для тех слов, чьи биты в эскизах совпадают.
- Кодирование слов, отсутствующих в эскизе, как «Вставка», остальных — на основе результатов поиска.



Пример: если скетч представлен 64-битной двоичной строкой, мы извлекаем его последние 32 бита для формирования признака. Если признаки двух фрагментов идентичны, это указывает на схожесть $0,5 = 32/64$, что означает, что приблизительно половина их содержимого идентична, и такой схожести достаточно для запуска дельта-кодирования.



Итого:

- 1) Высчитываем отпечаток для каждого слова в базовом чанке и заносим в таблицу
- 2) Определить, существует ли каждое слово входного фрагмента в базовом фрагменте
- 3) Не существующие по эскизу слова кодируем как Insert, остальные ищем в Fp

