Оптимизация алгоритмов дельта-кодирования Gdelta в системе MarLine

На момент 16.10:
1) Реализована версия SpeedSketch в виде, задуманном авторами исходной статьи
2) Исправлены замечания ревьюера
3) Выполнены первые замеры в сравнении с реализацией MarLine до внедрения SpeedSketch

Замеры коэффициента дедупликации и общего времени:

Метрика	До SpeedSketch	Текущая версия	Δ
cdc_ratio	1.158082	1.158082	0
sbc_ratio	1.949388	1.326497	−0.6229 (−32.0%)
stored, MiB	677.99	996.61	+318.62 (+47.0%)
scrub, s	28.93	29.14	+0.21 (+0.7%)
scrub, MiB/s	45.70	45.39	−0.31 (−0.7%)

Замеры времени по этапам:

Этап	**До SpeedSketch**	**Текущая версия**	**Δ**
Hash	1.53	1.145	−0.385 (−25.2%)
Cluster	1.85	0.0036	−1.846 (−99.8%)
Encode	25.5	27.99	+2.49 (+9.8%)
Σ ≈ scrub	28.88	29.14	+0.26

Промежуточные выводы:

1) Реализация в текущем виде неэффективна: добились только ускорения кластеризации, сильно пожертвовали памятью
2) SpeedSketch кластеризует по точному совпадению 32-битной фичи. Фича - это младшие 32 бита скетча, ложноположительных срабатываний на поиск базового блока практически нет, ложноотрицательные на очень похожих блоках многочисленны.
3) Точное совпадение фрагментирует чанки на одиночные кластеры, а *encode_cluster* строит таблицу отпечатков для каждого кластера. Теряем время на этапе *encode*.